

Directed Acyclic Graphs - Exemplos Capítulo 3

Isabela Diniz Cia

Educação superior aumenta os rendimentos

Explicação e Análise do Código

Este código executa uma simulação de Monte Carlo baseada no modelo de capital humano do Capítulo 3 (Grafos Acíclicos Dirigidos) . O objetivo é demonstrar como o viés de seleção surge em estimações ingênuas e como a aplicação do Critério da Porta dos Fundos (Backdoor Criterion) permite recuperar o verdadeiro efeito causal

```
# Baixando as bibliotes
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2     4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr       1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(broom)
```

```
# Geração da Amostra
set.seed(1000)
n <- 10000
```

1. O Processo Gerador de Dados (DGP)

O código simula uma população fictícia de 10.000 pessoas criando cinco variáveis encadeadas segundo a estrutura do DAG de capital humano:

- **background (B)**: Fatores ambientais e genéticos não observados (inteligência, motivação).
- **pe (PE)**: Escolaridade dos pais, determinada pelo **background**.
- **income (I)**: Renda da família, influenciada pela **escolaridade dos pais (PE)**.
- **college (D)**: A decisão de fazer faculdade (*variável de tratamento*), influenciada pelo **background**, pela **escolaridade dos pais** e pela **renda da família**.
- **earnings (Y)**: Salário do indivíduo (*variável de resultado*), determinado pela **faculdade** e pela **renda familiar**.

O Valor Verdadeiro (**ATE**): Na equação do salário (**earnings**), o coeficiente atribuído à **faculdade** é exatamente 2.0. Portanto, o efeito causal médio real do ensino superior nos ganhos é de 2 unidades monetárias.

```
# O Processo Gerador de Dados (DGP)
data <- tibble(
  background = rnorm(n), # Fatores não observados
  pe = 1 + 1 * background + rnorm(n), # Escolaridade dos pais
  income = 1 + 5 * pe + rnorm(n), # Renda da família
  college = 1 + 1 * background + 1 * pe + 1 * income + rnorm(n),
  earnings = 1 + 2 * college + 1 * income + rnorm(n) # (Resultado): Salário da pessoa.
)

head(data)
```

```
# A tibble: 6 x 5
  background      pe income college earnings
      <dbl>   <dbl>   <dbl>   <dbl>   <dbl>
1    -0.446    1.50    8.81    10.3    30.0
2    -1.21   -0.580   -1.66   -1.40   -5.13
3     0.0411  0.811    4.38    8.15    20.4
4     0.639   1.63    9.91   12.8    38.3
5    -0.787   1.37    7.75    9.92    28.0
6    -0.385  -1.86   -7.16  -10.0   -25.8
```

2. Modelo Ingênuo (naive_model)

- Regressão: `lm(earnings ~ college)`.

- O Problema: A comparação simples de salários entre quem fez e quem não fez faculdade ignora que existem três caminhos da porta dos fundos (**backdoor paths**) abertos conectando a faculdade aos ganhos:

$$D \leftarrow I \rightarrow Y$$

$$D \leftarrow PE \rightarrow I \rightarrow Y$$

$$D \leftarrow B \rightarrow PE \rightarrow I \rightarrow Y$$

Resultado: Como essas portas dos fundos não foram bloqueadas, o modelo atribui aos estudos o efeito de variáveis de confusão (como vir de famílias mais pobres). Isso gera uma estimativa enviesada de 2,758.

```
# Roda uma regressão simples de salário (earnings) em função apenas da faculdade (college)
naive_model <- lm(earnings ~ college, data = data)
summary(naive_model)
```

Call:

```
lm(formula = earnings ~ college, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-5.1409	-0.9500	0.0133	0.9446	5.7643

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.930786	0.018367	50.68	<2e-16 ***
college	2.759991	0.001499	1840.85	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.391 on 9998 degrees of freedom

Multiple R-squared: 0.9971, Adjusted R-squared: 0.9971

F-statistic: 3.389e+06 on 1 and 9998 DF, p-value: < 2.2e-16

3. Modelo Ajustado (adjusted_model)

- **Regressão:** `lm(earnings ~ college + income)`
- **A Solução Causal:** Analisando os três caminhos da porta dos fundos, nota-se que a renda familiar (`income`) é um não-colisor presente em todos eles.

- **Satisfação do Critério da Porta dos Fundos:** Controlar unicamente pela renda é minimamente suficiente para bloquear simultaneamente os três caminhos de confusão.
- **Resultado:** O coeficiente estimado para a faculdade ajusta-se para 1,995 (com intervalo de confiança de 95% entre 1,98 e 2,01), isolando e recuperando com precisão o verdadeiro efeito causal de 2.0.

```
# Inclui a renda familiar (income) como variável de controle na regressão
adjusted_model <- lm(earnings ~ college + income, data = data)
summary(adjusted_model)
```

Call:

```
lm(formula = earnings ~ college + income, data = data)
```

Residuals:

Min	1Q	Median	3Q	Max
-4.0934	-0.6722	-0.0095	0.6638	3.5237

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.993588	0.013229	75.11	<2e-16 ***
college	1.999847	0.007947	251.64	<2e-16 ***
income	1.000689	0.010365	96.54	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.001 on 9997 degrees of freedom

Multiple R-squared: 0.9985, Adjusted R-squared: 0.9985

F-statistic: 3.278e+06 on 2 and 9997 DF, p-value: < 2.2e-16

Lição Principal

Para eliminar o viés em uma pesquisa empírica, **não é necessário controlar todas as variáveis do universo**. Mapear o DAG do problema permite identificar o conjunto **minimamente suficiente** de covariáveis que satisfaz o critério da porta dos fundos, garantindo a identificação do efeito causal com eficiência estatística

Discriminação de gênero no mercado de trabalho

Explicação e Análise do Código

Este código em R executa uma simulação baseada no **Capítulo 3 (Grafos Acíclicos Dirigidos)** para demonstrar empiricamente como o viés de colisor (collider bias) pode perverter estimativas estatísticas ao estudar discriminação de gênero no mercado de trabalho

```
# Baixando as bibliotecas
library(tidyverse)
library(stargazer)
```

Please cite as:

Hlavac, Marek (2022). stargazer: Well-Formatted Regression and Summary Statistics Tables.

R package version 5.2.3. <https://CRAN.R-project.org/package=stargazer>

1. O Processo Gerador de Dados (DGP)

O código cria uma população fictícia de 10.000 indivíduos seguindo as regras do DAG de discriminação:

- **female** e **discrimination** (D): Metade da população é do sexo feminino e todas as mulheres sofrem discriminação ($D = \text{female}$)
- **ability** (A): Habilidade individual não observada, sorteada de forma independente do gênero
- **occupation** (O): Nível ocupacional ou cargo. É afetado positivamente pela habilidade ($+2 \times A$) e negativamente pela discriminação nas promoções ($-2 \times D$). A ocupação é um colisor no caminho $D \rightarrow O \leftarrow A \rightarrow Y$
- **wage** (Y): Salário do indivíduo. É reduzido diretamente pela discriminação salarial ($-1 \times D$), e aumentado pela ocupação ($+1 \times O$) e pela habilidade ($+2 \times A$)

Valores Reais Programados no Código:

- Efeito Direto da Discriminação: -1.0 .
- Efeito Indireto (Barreira em Promoções): $-2.0 \times 1.0 = -2.0$.
- Efeito Total Real da Discriminação: $-1.0 + (-2.0) = -3.0$.

```
set.seed(123)
tb <- tibble(
  female = ifelse(runif(10000) >= 0.5, 1, 0),
  ability = rnorm(10000),
  discrimination = female, # Discrimination linked to being female
  occupation = 1 + 2 * ability - 2 * discrimination + rnorm(10000),
  wage = 1 - discrimination + occupation + 2 * ability + rnorm(10000)
)

head(tb)
```

```
# A tibble: 6 x 5
  female ability discrimination occupation wage
  <dbl>   <dbl>         <dbl>         <dbl> <dbl>
1     0 -0.494             0         -1.34 -2.13
2     1  1.13             1          0.676 1.80
3     0 -1.15             0         -2.15 -2.87
4     1  1.48             1          2.93  6.41
5     1  0.916            1          1.45  3.49
6     0  0.335             0          3.06  4.24
```

2. As Três Regressões e o Pacote stargazer

lm_1 — Modelo Incondicional (wage ~ female):

- **O que faz:** Compara diretamente os salários de homens e mulheres sem incluir covariáveis.
- **Resultado:** Captura o *efeito total da discriminação* (efeito direto mais a perda indireta por menor acesso a cargos altos). O coeficiente estimado fica em aproximadamente **-3,074**.

lm_2 — Modelo Condicional Enviesado (wage ~ female + occupation):

- **O que faz:** Inclui a ocupação como controle para comparar homens e mulheres no mesmo cargo.
- **O Problema do Colisor:** A ocupação (O) é um colisor no caminho $D \rightarrow O \leftarrow A \rightarrow Y$. Condicionar na ocupação bloqueia o efeito indireto real e *abre o caminho da porta dos fundos espúrio* entre discriminação e habilidade não observada.
- **Resultado:** O viés de colisor introduz uma seleção artificial (mulheres no mesmo cargo precisam ter habilidade A muito superior) que perverte o modelo, fazendo o coeficiente da discriminação mudar de sinal e se tornar falsamente positivo (**+0,601**).

lm_3 — Modelo Totalmente Condicional Imparcial (wage ~ female + occupation + ability):

- **O que faz:** Controla a ocupação e a habilidade não observada (A) simultaneamente.
- **A Solução Causal:** Controlar pela habilidade fecha o caminho da porta dos fundos que havia sido aberto pelo colisor.
- **Resultado:** O modelo consegue isolar e recuperar com precisão o *efeito causal direto* da discriminação salarial, retornando ao valor real próximo de **-0,994** (aproximadamente -1.0).

stargazer(...):

- **Função:** Gera uma tabela comparativa formatada exibindo os resultados das três regressões lado a lado.

```
# Regressions
lm_1 <- lm(wage ~ female, tb) # Unconditional, biased
lm_2 <- lm(wage ~ female + occupation, tb) # Conditional, still biased
lm_3 <- lm(wage ~ female + occupation + ability, tb) # Fully conditional, unbiased

# Display results with stargazer
stargazer(lm_1, lm_2, lm_3, type = "text",
          column.labels = c("Unconditional (Biased)",
                           "Conditional (Biased)",
                           "Fully Conditional (Unbiased)"),
          dep.var.caption = "Dependent variable: Wage",
          omit.stat = c("f", "ser"))
```

=====			
Dependent variable: Wage			

	wage		
	Unconditional (Biased)	Conditional (Biased)	Fully Conditional (Unbiased)
	(1)	(2)	(3)

female	-3.066*** (0.085)	0.587*** (0.030)	-1.050*** (0.028)
occupation		1.796*** (0.006)	0.987*** (0.010)

ability			2.033*** (0.022)
Constant	2.023*** (0.060)	0.222*** (0.020)	1.025*** (0.017)

Observations	10,000	10,000	10,000
R2	0.114	0.912	0.952
Adjusted R2	0.114	0.912	0.952

Note: *p<0.1; **p<0.05; ***p<0.01

Lição principal

Controlar por características do trabalho (como cargo ou ocupação) para tentar “limpar” a estimativa de discriminação é um exemplo clássico de **“controle ruim” (bad control)**. Como a habilidade individual (A) raramente é observada em dados reais, incluir a ocupação abre o viés de colisor e gera a ilusão estatística de que a discriminação não existe ou é positiva.